

# Πρόβλεψη Καρδιοπάθειας (HeartDisease) με Μεθόδους Μηχανικής Μάθησης

**Φοιτητής(A.M.):** Περικλής Παύλου(3220158)

**Μάθημα:** Μέθοδοι Στατιστικής και Μηχανικής Μάθησης

**Καθηγητές:** Δημήτρης Καρλής - Κωνσταντίνος Πανούσης

**Ημερομηνία Υποβολής:** 9 Ιανουαρίου 2026

## 0. Σύντομη περίληψη

Σε αυτή την εργασία στόχος είναι να προβλέψουμε αν ένας ασθενής έχει καρδιοπάθεια (**HeartDisease: Yes/No**) με βάση κλινικά και δημογραφικά χαρακτηριστικά. Χρησιμοποιήσαμε το διαθέσιμο dataset (με αριθμητικές και κατηγορικές μεταβλητές) και εφαρμόσαμε διαφορετικές μεθόδους ταξινόμησης: **Naive Bayes**, **bagging με δέντρα**, **Random Forest** και **boosting (XGBoost)**. Η αξιολόγηση έγινε με **train/test split** και **cross-validation** στο training set, με μέτρα όπως **Accuracy**, **Precision**, **Recall**, **F1**, **ROC/AUC** και **confusion matrix**. Με βάση τα αποτελέσματα στο test set, το μοντέλο που είχε τη συνολικά καλύτερη επίδοση (κυρίως σε **AUC**) ήταν το **XGBoost**.

## 1. Περιγραφή προβλήματος

Το πρόβλημα είναι ένα **δυναμικό πρόβλημα ταξινόμησης (binary classification)**: για κάθε παρατήρηση θέλουμε να προβλέψουμε μία από δύο κατηγορίες, **Yes** (υπάρχει καρδιοπάθεια) ή **No** (δεν υπάρχει καρδιοπάθεια).

Η μεταβλητή-στόχος (**target**) είναι η **HeartDisease**, ενώ οι υπόλοιπες μεταβλητές χρησιμοποιούνται ως **χαρακτηριστικά (features)** για την πρόβλεψη.

Στην αξιολόγηση θεωρούμε ως **θετική κλάση (positive class)** την **Yes**, γιατί μας ενδιαφέρει ιδιαίτερα να εντοπίζουμε σωστά τα άτομα που έχουν καρδιοπάθεια. Αυτό επηρεάζει άμεσα το πώς υπολογίζονται μετρικές όπως:

- **Recall / Sensitivity**: από όσους πραγματικά είναι *Yes*, πόσους βρήκε σωστά το μοντέλο;
- **Precision**: από όσους προέβλεψε *Yes*, πόσοι ήταν πράγματι *Yes*;
- **Confusion Matrix**: παρουσιάζει αναλυτικά σωστές/λάθος προβλέψεις (TP, FP, TN, FN).

## 2. Dataset & Μεταβλητές

### 2.1 Γενικά στοιχεία dataset

Το dataset περιλαμβάνει **N = 918** παρατηρήσεις (ασθενείς) και **12** μεταβλητές συνολικά, εκ των οποίων η μία είναι η μεταβλητή-στόχος (**HeartDisease**) και οι υπόλοιπες είναι χαρακτηριστικά (features) που χρησιμοποιούνται για πρόβλεψη.

### 2.2 Μεταβλητές (features) + “κρυφά” missing values

Παρακάτω δίνεται μια σύντομη κατηγοριοποίηση των μεταβλητών σε αριθμητικές και κατηγορικές.

**Αριθμητικές (numeric):**

- **Age** (έτη)
- **RestingBP** (mm Hg)
- **Cholesterol** (mg/dl)
- **MaxHR** (μέγιστος καρδιακός ρυθμός)
- **Oldpeak** (ST depression, αριθμητική τιμή)

**Κατηγορικές (categorical):**

- **Sex** (M/F)
- **ChestPainType** (TA, ATA, NAP, ASY)
- **FastingBS** (0/1)
- **RestingECG** (Normal, ST, LVH)
- **ExerciseAngina** (Y/N)
- **ST\_Slope** (Up, Flat, Down)

**Μεταβλητή στόχος (target):**

- **HeartDisease** (0/1 → No/Yes)

**Έλεγχος NA & “κρυφών” missing values**

- Το αρχικό dataset **δεν είχε καθόλου NA** (`sum(is.na(df_raw)) = 0`).
- Ωστόσο, εντοπίστηκαν μη ρεαλιστικές τιμές **0** που πρακτικά λειτουργούν σαν “κρυφά” missing values:
  - **RestingBP**: **1** τιμή ίση με 0
  - **Cholesterol**: **172** τιμές ίσες με 0Για αυτό:
  - Στο **EDA** αντιμετώπισα τα 0 ως **missing** ( $0 \rightarrow \text{NA}$ ), ώστε να μην “στραβώνουν” τα γραφήματα/στατιστικά.
  - Στη **μοντελοποίηση**, έκανα  $0 \rightarrow \text{NA}$  και μετά **imputation μόνο από το TRAIN** (αναλυτικά στην ενότητα 3.2).

**2.3 Σχόλιο για ανισορροπία κλάσεων (class imbalance)**

Η κατανομή της μεταβλητής-στόχου είναι:

- **No: 410 (44.66%)**
- **Yes: 508 (55.34%)**

Άρα υπάρχει μια μικρή υπεροχή της κλάσης **Yes**, αλλά **δεν πρόκειται για ακραίο imbalance**.

---

## 3. Προεπεξεργασία & Έλεγχοι ποιότητας δεδομένων

### 3.1 Έλεγχοι τιμών & “καθάρισμα” κατηγοριών

Πριν την ανάλυση/μοντελοποίηση έγιναν βασικοί έλεγχοι εγκυρότητας:

- Επιβεβαίωση ότι υπάρχουν όλες οι απαιτούμενες στήλες.

- Έλεγχος ότι οι κατηγορικές μεταβλητές έχουν επιτρεπτές τιμές.
- **Normalization** σε κατηγορίες ώστε να αποφύγω “σπασμένα” levels (κενά/πεζά/κεφαλαία):
  - **RestingECG**: Normal / ST / LVH
  - **ST\_Slope**: Up / Flat / Down
  - αντίστοιχα για **Sex**, **ChestPainType**, **ExerciseAngina**.

### 3.2 Χειρισμός μη-έγκυρων 0 σε RestingBP/Cholesterol (EDA vs Modeling)

Οι τιμές **0** στα **RestingBP** και **Cholesterol** δεν είναι ρεαλιστικές ως πραγματικές μετρήσεις, οπότε τις αντιμετωπίζω ως **missing/invalid**:

- **Στο EDA (Μέρος A):**  
Έκανα **0** → **NA global** (μόνο για την περιγραφική ανάλυση).
- **Στη Μοντελοποίηση (Μέρος B):**  
Για να μη χαθούν πολλές γραμμές (ειδικά στη χοληστερόλη), έκανα:
  1. **split** σε train/test
  2. **0** → **NA**
  3. **imputation** με **mean του TRAIN** και εφαρμογή και στο TEST (ώστε να μη γίνει leakage).

### 3.3 Μετατροπές τύπων (types)

- Αριθμητικές μεταβλητές → **numeric**
- Κατηγορικές → **factor**
- Στόχος **HeartDisease** → factor με επίπεδα **No, Yes**

### 3.4 Γιατί “no leakage”

Για δίκαιη αξιολόγηση, φρόντισα ώστε **ό,τι υπολογίζεται από δεδομένα** (π.χ. mean για imputation, dummy encoding για XGBoost) να “μαθαίνεται” **μόνο από το TRAIN** και μετά να εφαρμόζεται στο TEST.

---


## 3.5 Γραφήματα, περιγραφικά στατιστικά, outliers & συσχετίσεις

Σε αυτό το σημείο μάζεψα όλα τα βασικά ευρήματα από τα γραφήματα:

- Κατανομή στόχου
- Numerics (histogram + boxplot) **μαζί με στατιστικά** και **outliers**
- Categoricals (αναλογίες) **μαζί με counts/ποσοστά**
- Correlation matrix (numerics)
- **Ποσοτικοποίηση “σήματος” (effect sizes) για τα numerics**
- **Απόφαση/χειρισμός outliers & σχόλιο πολυσυγγραμμικότητας**
- **Σύνδεση EDA → τι περιμένω να “οδηγήσει” τα μοντέλα**

---

#### 3.5.1 Κατανομή στόχου (HeartDisease)




**Σχόλιο:** Οι δύο κλάσεις είναι σχετικά κοντά (λίγο περισσότερα **Yes**), άρα δεν υπάρχει ακραία ανισορροπία.


3.5.2 Συνεχείς μεταβλητές (numeric)

Για κάθε numeric έβαλα histogram και boxplot **δίπλα-δίπλα** και ακριβώς από κάτω τα βασικά στατιστικά και τα outliers.

Age



Histogram: Age



Boxplot: Age


Βασικά στατιστικά (ανά κλάση):

| Κλάση | n   | mean | median | sd   | min | max |
|-------|-----|------|--------|------|-----|-----|
| No    | 410 | 50.6 | 51     | 9.44 | 28  | 76  |
| Yes   | 508 | 55.9 | 57     | 8.73 | 31  | 77  |

Outliers (IQR rule): 0

Τι βλέπω: Στο **Yes** η ηλικία είναι εμφανώς υψηλότερη (ανεβαίνει το median/mean).

RestingBP (στο EDA: 0 → NA)




Βασικά στατιστικά (ανά κλάση):

| Κλάση | n   | mean | median | sd   | min | max |
|-------|-----|------|--------|------|-----|-----|
| No    | 410 | 130  | 130    | 16.5 | 80  | 190 |
| Yes   | 507 | 134  | 132    | 18.9 | 92  | 200 |

Outliers (IQR rule): 27

**Τι βλέπω:** Οι κατανομές είναι σχετικά κοντά, αλλά το **Yes** τείνει προς ελαφρώς μεγαλύτερες τιμές και έχει αρκετά outliers (αναμενόμενο σε κλινικά δεδομένα).

Cholesterol (στο EDA: 0 → NA — επηρεάζονται πολλές γραμμές)




Βασικά στατιστικά (ανά κλάση):

| Κλάση | n   | mean | median | sd   | min | max |
|-------|-----|------|--------|------|-----|-----|
| No    | 390 | 239  | 232    | 55.4 | 85  | 564 |
| Yes   | 356 | 251  | 246    | 62.5 | 100 | 603 |


Outliers (IQR rule): 23

Τι βλέπω: Μεγάλο εύρος και αρκετές πολύ υψηλές τιμές. Η διαφορά Yes/No υπάρχει αλλά δεν είναι “κραυγαλέα” όσο σε άλλα features.

MaxHR



Histogram: MaxHR



Boxplot: MaxHR


Βασικά στατιστικά (ανά κλάση):

| Κλάση | n   | mean | median | sd   | min | max |
|-------|-----|------|--------|------|-----|-----|
| No    | 410 | 148  | 150    | 23.3 | 69  | 202 |
| Yes   | 508 | 128  | 126    | 23.4 | 60  | 195 |


Outliers (IQR rule): 2

Τι βλέπω: Εδώ η διαφορά είναι πολύ καθαρή: στο **Yes** το MaxHR είναι αισθητά χαμηλότερο.

Oldpeak



Histogram: Oldpeak



Boxplot: Oldpeak

Βασικά στατιστικά (ανά κλάση):


| Κλάση | n   | mean  | median | sd    | min  | max |
|-------|-----|-------|--------|-------|------|-----|
| No    | 410 | 0.408 | 0.0    | 0.700 | -1.1 | 4.2 |
| Yes   | 508 | 1.27  | 1.2    | 1.15  | -2.6 | 6.2 |

**Outliers (IQR rule):** 16

**Τι βλέπω:** Στο **Yes** οι τιμές είναι μετατοπισμένες προς τα πάνω και έχουν μεγαλύτερη διασπορά.

**Σημείωση:** Ναι, το **Oldpeak** μπορεί να είναι και αρνητικό (ουσιαστικά “αντίστροφο” ST depression / ST elevation), οπότε δεν είναι από μόνο του λάθος—αρκεί να είναι μέσα σε λογικά όρια (και εδώ φαίνεται να είναι).

3.5.3 Συσχετίσεις (μόνο αριθμητικές μεταβλητές)




**Σύντομο σχόλιο:**

- Η πιο έντονη σχέση είναι **Age–MaxHR** με αρνητική συσχέτιση ( $r \approx -0.38$ ): όσο αυξάνει η ηλικία, τείνει να μειώνεται το MaxHR.
- Οι υπόλοιπες συσχετίσεις είναι χαμηλές/μέτριες, άρα δεν φαίνεται έντονο θέμα πολυσυγγραμμικότητας μόνο από τα numerics.

3.5.4 Κατηγορικές μεταβλητές vs HeartDisease (αναλογίες + ποσοστά)

- Σε κάθε γράφημα κρατάω και τα counts/ποσοστά, για να “στέκει” το συμπέρασμα με νούμερα.


**FastingBS**



| FastingBS | No  | Yes | P(Yes) |
|-----------|-----|-----|--------|
| 0         | 366 | 338 | 0.480  |
| 1         | 44  | 170 | 0.794  |

**Τι βλέπω:** Στο **FastingBS=1** η πιθανότητα Yes είναι πολύ υψηλότερη.

## Sex




| Sex | No  | Yes | P(Yes) |
|-----|-----|-----|--------|
| F   | 143 | 50  | 0.259  |
| M   | 267 | 458 | 0.632  |

**Τι βλέπω:** Στους **M** υπάρχει πολύ μεγαλύτερο ποσοστό **Yes**.

## ChestPainType






| ChestPainType | No  | Yes | P(Yes) |
|---------------|-----|-----|--------|
| ASY           | 104 | 392 | 0.790  |
| ATA           | 149 | 24  | 0.139  |
| NAP           | 131 | 72  | 0.355  |
| TA            | 26  | 20  | 0.435  |

Τι βλέπω: Το **ASY** έχει πολύ υψηλό ποσοστό Yes, ενώ το **ATA** πολύ χαμηλό.


RestingECG



| RestingECG | No  | Yes | P(Yes) |
|------------|-----|-----|--------|
| LVH        | 82  | 106 | 0.564  |
| Normal     | 267 | 285 | 0.516  |
| ST         | 61  | 117 | 0.657  |

Τι βλέπω: Υπάρχουν διαφορές (π.χ. ST πιο “Yes-heavy”), αλλά όχι τόσο έντονες όσο σε άλλες κατηγορικές.


## ExerciseAngina



| ExerciseAngina | No  | Yes | P(Yes) |
|----------------|-----|-----|--------|
| N              | 355 | 192 | 0.351  |
| Y              | 55  | 316 | 0.852  |

**Τι βλέπω:** Είναι από τα πιο “καθαρά” σήματα: στο **Y** η πιθανότητα Yes είναι τεράστια.

## ST\_Slope



| ST_Slope | No  | Yes | P(Yes) |
|----------|-----|-----|--------|
| Down     | 14  | 49  | 0.778  |
| Flat     | 79  | 381 | 0.828  |
| Up       | 317 | 78  | 0.197  |

**Τι βλέπω:** Στο **Up** κυριαρχεί το No, ενώ **Flat/Down** είναι πολύ “Yes-heavy”.

## 3.5.5 Μικρή σύνοψη ευρημάτων (τι κρατάω για μοντελοποίηση)

Με βάση τα παραπάνω, οι μεταβλητές που δείχνουν πιο “καθαρή” σχέση με το HeartDisease είναι:

- **MaxHR** (πολύ έντονη διαφορά ανά κλάση)
- **Oldpeak** (μετατόπιση προς υψηλότερες τιμές στο Yes)
- **Age** (Yes σε μεγαλύτερες ηλικίες)
- **ExerciseAngina**, **ST\_Slope**, **ChestPainType**, **FastingBS** (πολύ ισχυρά categorical σήματα)

Για τη μοντελοποίηση χρησιμοποίησα **όλες τις μεταβλητές** (με σωστό preprocessing/encoding), ώστε τα μοντέλα να αποφασίσουν ποιο συνδυασμό αξιοποιούν καλύτερα.

### 3.5.6 Ποσοτικοποίηση “σήματος” των numeric features (effect sizes)

Για να μετρήσω **πόσο** διαχωρίζει κάθε αριθμητική μεταβλητή τις δύο ομάδες (HeartDisease=Yes vs No), υπολόγισα δύο συμπληρωματικά μέτρα:

- **Point-biserial r**: κατεύθυνση και ένταση γραμμικής σχέσης με δυαδικό target.
- **Cohen’s d**: τυποποιημένη διαφορά μέσων όρων (σε μονάδες τυπικής απόκλισης) → πιο άμεσο για “πόσο χωρίζουν οι ομάδες”.

**Γιατί Cohen’s d** : το target είναι **δύο ομάδες (Yes/No)** και θέλω ένα **standardized μέτρο διαφοράς μέσων** που να συγκρίνεται εύκολα μεταξύ μεταβλητών με διαφορετικές μονάδες.

### 3.5.7 Αποτελέσματα effect sizes (numeric features)

| Variable    | r (point-biserial) | Cohen’s d | mean(No) | mean(Yes) | Σχόλιο                                |
|-------------|--------------------|-----------|----------|-----------|---------------------------------------|
| Oldpeak     | 0.404              | 0.887     | 0.408    | 1.270     | Πολύ ισχυρός διαχωρισμός (Yes ↑)      |
| MaxHR       | -0.400             | -0.878    | 148.0    | 128.0     | Πολύ ισχυρός διαχωρισμός (Yes ↓)      |
| Age         | 0.282              | 0.591     | 50.6     | 55.9      | Μέτριο–ισχυρό σήμα (Yes ↑)            |
| RestingBP   | 0.118              | 0.239     | 130.0    | 134.0     | Αδύναμο σήμα                          |
| Cholesterol | 0.104              | 0.209     | 239.0    | 251.0     | Αδύναμο σήμα (και πολλά 0→NA στο EDA) |

#### Συμπέρασμα (numerics):

- Τα πιο “δυνατά” αριθμητικά features για διάκριση Yes/No είναι τα **Oldpeak** και **MaxHR** ( $|d| \approx 0.88$ ).
- Η **Age** δίνει επίσης χρήσιμο σήμα ( $d \approx 0.59$ ).
- **RestingBP** και **Cholesterol** έχουν μικρό effect μεμονωμένα, αλλά μπορούν να συνεισφέρουν συνδυαστικά σε ensemble/boosting.

### 3.5.8 Outliers: τι αποφάσισα και γιατί (διατήρηση/μετασχηματισμός/αποκλεισμός)

Τα outliers εντοπίστηκαν με τον **κανόνα IQR ( $1.5 \times IQR$ )**. Σημείωση για μια πιθανή “παρεξήγηση”:

- Στα σχήματα αναφέρω **τον αριθμό outliers με IQR rule όπως υπολογίστηκε συνολικά** για κάθε μεταβλητή (δηλ. πάνω σε όλο το dataset).
- Όμως, στα **boxplots ανά κλάση (No/Yes)**, τα όρια του IQR υπολογίζονται **ξεχωριστά μέσα σε κάθε ομάδα**.  
Άρα, μπορεί να εμφανίζονται **μικρές τελείες** (outlier points) σε κάποια ομάδα, ακόμα κι αν ο συνολικός έλεγχος outliers για τη μεταβλητή δίνει πολύ μικρό αριθμό ή και 0.

Συνεπώς, οι τελείες που φαίνονται στο boxplot του **Age** δεν σημαίνουν απαραίτητα ότι “έκανα λάθος”: απλώς το boxplot εφαρμόζει το IQR **ανά ομάδα**, ενώ ο αριθμός outliers που αναφέρω είναι **συνολικός**.

**Απόφαση:** Δεν αφαίρεσα outliers, γιατί:

- πολλά από αυτά μπορεί να είναι **πραγματικές ακραίες κλινικές τιμές** (high-risk περιπτώσεις) και όχι λάθη καταγραφής,
- τα μοντέλα που χρησιμοποιούνται (**Bagging / Random Forest / XGBoost**) είναι σχετικά **ανθεκτικά** σε outliers λόγω της δομής των δέντρων,
- η βασική διόρθωση ποιότητας δεδομένων έγινε στα **μη-ρεαλιστικά 0** σε **RestingBP/Cholesterol** (0→NA), και στο Μέρος Β έγινε **imputation χωρίς leakage** (μέσος όρος TRAIN).

---

### 3.5.9 Σχόλιο για πολυσυγγραμμικότητα (multicollinearity)

- Από τον πίνακα συσχετίσεων, δεν εμφανίζονται πολύ υψηλές συσχετίσεις στα numerics (π.χ.  $|r| > 0.8$ ).
- Η μεγαλύτερη σε απόλυτη τιμή είναι **Age–MaxHR ( $r \approx -0.38$ )**, που είναι **μέτρια**.
- Άρα, με βάση τα numerics **δεν υπάρχει ένδειξη σοβαρής πολυσυγγραμμικότητας**.

---

### 3.5.10 Feature Engineering (βασικό)

Η εκφώνηση αναφέρει “basic feature engineering”. Σε αυτή την εργασία:

- Δεν δημιουργήθηκαν νέες μεταβλητές, επειδή τα υπάρχοντα features είναι ήδη κλινικά ερμηνεύσιμα και τα ισχυρότερα σήματα (Oldpeak, MaxHR, ST\_Slope, ExerciseAngina, ChestPainType) προκύπτουν καθαρά από το EDA.
- Το “feature engineering” που εφάρμοσα πρακτικά ήταν:
  - σωστές **μετατροπές τύπων** (numeric/factor),
  - καθάρισμα κατηγοριών (normalization levels),
  - **0→NA + imputation** χωρίς leakage,
  - και **one-hot encoding** για XGBoost.

---

## 4. Μοντελοποίηση & Αξιολόγηση (Naive Bayes — Bagging/Random Forest — XGBoost)

Σε αυτή την ενότητα εφαρμόστηκαν οι μέθοδοι που ζητά η εκφώνηση:

1. **Naive Bayes** (baseline)
2. **Ensemble με bagging** (**Bagging Trees** και **Random Forest**)
3. **Boosting** (**XGBoost**)

Κοινός στόχος: **δίκαιη σύγκριση** με **ίδιο test set** και **ίδιο τρόπο αξιολόγησης** (Accuracy, Precision, Recall, F1, Confusion Matrix, ROC/AUC).

---

#### 4.1 Διαδικασία Train/Test & "no leakage" preprocessing

- Χωρίσαμε τα δεδομένα σε **Train 80% / Test 20%** με stratified split ως προς το target:
  - Train: **735** δείγματα
  - Test: **183** δείγματα
- Οι αναλογίες του target διατηρούνται σχεδόν ίδιες:
  - Train: No=0.4463, Yes=0.5537
  - Test: No=0.4481, Yes=0.5519

##### Imputation χωρίς leakage (RestingBP, Cholesterol):

- Στο train/test έγινε πρώτα **0** → **NA** για τις δύο μεταβλητές.
- Υπολογίστηκε ο **μέσος όρος μόνο στο TRAIN** και έγινε συμπλήρωση (imputation) τόσο στο train όσο και στο test με αυτόν τον train-mean.
- Έτσι, το test δεν "διαρρέει" πληροφορία στο training στάδιο.

##### Categorical encoding για XGBoost:

- Το **dummy/one-hot encoding** εκπαιδεύτηκε **μόνο στο TRAIN** και εφαρμόστηκε μετά στο TEST για συμβατές στήλες.
- 

#### 4.2 Μετρικές αξιολόγησης

Χρησιμοποιήθηκαν:

- Confusion Matrix** (TP, FP, TN, FN)
- Accuracy**
- Precision**
- Recall (Sensitivity)**
- F1-score**
- ROC curve & AUC**

Σημείωση: Χρησιμοποιήθηκε όριο ταξινόμησης **0.5** για να μετατρέπονται πιθανότητες σε κλάσεις (Yes/No).

---

#### 4.3 Naive Bayes (Baseline)

##### 4.3.1 Υπόθεση ανεξαρτησίας & ρεαλιστικότητα

Ο Naive Bayes υποθέτει ότι τα features είναι **υπό συνθήκη ανεξάρτητα** δεδομένης της κλάσης (Yes/No).

- Στο συγκεκριμένο dataset αυτό **δεν είναι πλήρως ρεαλιστικό**, γιατί υπάρχουν συσχετίσεις (π.χ. Age–MaxHR).
- Παρόλα αυτά, ο Naive Bayes συχνά αποδίδει καλά ως **baseline**, ειδικά όταν οι σχέσεις είναι "αρκετά" διαχωρίσιμες.

### 4.3.2 Cross-validation (TRAIN)

- Εκπαίδευση με **5-fold CV** πάνω στο TRAIN.
- Ρυθμίσεις: `Laplace=1`, `kernel=TRUE` (για πιο "ομαλές" κατανομές/πιθανότητες).


### 4.3.3 Αποτελέσματα στο TEST

#### Confusion Matrix (TEST):

- TN=68, FP=14
- FN=13, TP=88

#### Metrics (TEST):

- Accuracy: **0.852**
- Precision: **0.863**
- Recall: **0.871**
- F1: **0.867**
- AUC: **0.930**



**Σχόλιο:** Πολύ καλό baseline (AUC≈0.93), αλλά υστερεί σε συνολική απόδοση από τα ensembles/boosting.

---

## 4.4 Bagging Trees (Ensemble / Bagging)

### 4.4.1 Γιατί bagging;

Το bagging μειώνει τη διακύμανση (variance) ενός ασταθούς μοντέλου (π.χ. decision trees), με εκπαίδευση πολλών δέντρων σε bootstrap δείγματα και συνδυασμό προβλέψεων.

### 4.4.2 Tuning (TRAIN με CV)

Έγινε grid search με 5-fold CV στο TRAIN για:

- `nbagg` ∈ {10, 50, 100, 200}
- `maxdepth` ∈ {1, 3, 5, 10}

**Best config (CV):**


- **nbagg=50, maxdepth=5**
- CV AUC  $\approx$  **0.914**

**4.4.3 Αποτελέσματα στο TEST****Confusion Matrix (TEST):**

- TN=71, FP=11
- FN=11, TP=90

**Metrics (TEST):**

- Accuracy: **0.880**
- Precision: **0.891**
- Recall: **0.891**
- F1: **0.891**
- AUC: **0.927**



**Σχόλιο:** Σημαντική βελτίωση έναντι του Naive Bayes (ιδίως σε Accuracy/F1). Το bagging είναι αρκετά σταθερό και γενικά πιο "ανθεκτικό" σε θόρυβο.

---

## 4.5 Random Forest (Ensemble / Bagging + Feature Subsampling)

### 4.5.1 Γιατί Random Forest;

Το Random Forest είναι bagging δέντρων με επιπλέον τυχαιοποίηση (feature subsampling σε κάθε split), που συνήθως:

- μειώνει περαιτέρω τη συσχέτιση μεταξύ δέντρων,
- αυξάνει τη γενίκευση.

### 4.5.2 Tuning (TRAIN με CV)

Grid search με 5-fold CV στο TRAIN:

- `ntree`  $\in \{50, 100, 200, 500\}$
- `maxnodes`  $\in \{NA, 10, 20, 40\}$
- `mtry`  $\in \{2, 3, 4, 5\}$

#### Best config (CV):

- `ntree=500`, `maxnodes=NA`, `mtry=2`
- CV AUC  $\approx$  **0.932**


#### 4.5.3 Αποτελέσματα στο TEST

##### Confusion Matrix (TEST):

- TN=71, FP=11
- FN=10, TP=91

##### Metrics (TEST):

- Accuracy: **0.885**
- Precision: **0.892**
- Recall: **0.901**
- F1: **0.897**
- AUC: **0.926**



**Σχόλιο:** Από τα πιο ισχυρά μοντέλα, με πολύ καλή ισορροπία precision/recall και υψηλή ακρίβεια.

---

## 4.6 XGBoost (Boosting)

### 4.6.1 Γιατί Boosting / XGBoost;

Το boosting χτίζει μοντέλα διαδοχικά, διορθώνοντας τα λάθη των προηγούμενων. Το XGBoost είναι ιδιαίτερα αποδοτικό και συνήθως πολύ ισχυρό σε tabular δεδομένα.

### 4.6.2 Tuning υπερπαραμέτρων (TRAIN με xgb.cv)

- Έγινε **5-fold CV** στο TRAIN με **early stopping** (30 rounds).



- Δοκιμάστηκαν:
  - $\text{eta (learning rate)} \in \{0.01, 0.05, 0.1, 0.3\}$
  - $\text{max\_depth} \in \{2, 4, 6\}$
  - Μέχρι  $\text{nrounds}=2000$  (με early stopping)

#### Best config (CV):

- **eta=0.05, max\_depth=4, best\_nrounds=85**
- CV AUC  $\approx$  **0.936**


#### 4.6.3 Αποτελέσματα στο TEST

##### Confusion Matrix (TEST):

- TN=71, FP=11
- FN=10, TP=91


##### Metrics (TEST):

- Accuracy: **0.885**
- Precision: **0.892**
- Recall: **0.901**
- F1: **0.897**
- AUC: **0.936** (καλύτερο AUC)



#### 4.6.4 Ερμηνευσιμότητα: Feature Importance (XGBoost)

Παρακάτω φαίνεται η σχετική σημαντικότητα χαρακτηριστικών (Gain):



**Σχόλιο:** Τα πιο “ισχυρά” σήματα για το XGBoost είναι μεταβλητές όπως:

- **ST\_Slope** (ιδιαίτερα το επίπεδο Up/Flat),
- **ChestPainType** (ιδιαίτερα ASY),
- **Oldpeak**, και στη συνέχεια **Cholesterol**, **ExerciseAngina**, **MaxHR**, **RestingBP**, **Age**.

## 4.7 Συγκριτικός πίνακας αποτελεσμάτων (TEST)

| Model          | Ρυθμίσεις (Detail)             | Accuracy     | Precision    | Recall       | F1           | AUC          |
|----------------|--------------------------------|--------------|--------------|--------------|--------------|--------------|
| <b>XGBoost</b> | eta=0.05, depth=4, nrounds=85  | <b>0.885</b> | 0.892        | <b>0.901</b> | <b>0.897</b> | <b>0.936</b> |
| Naive Bayes    | Laplace=1, kernel=TRUE         | 0.852        | 0.863        | 0.871        | 0.867        | 0.930        |
| Bagging Trees  | nbagg=50, depth=5              | 0.880        | <b>0.891</b> | 0.891        | 0.891        | 0.927        |
| Random Forest  | ntree=500, maxnodes=NA, mtry=2 | <b>0.885</b> | 0.892        | <b>0.901</b> | <b>0.897</b> | 0.926        |

## 4.8 Συζήτηση: προγνωστική ικανότητα, σταθερότητα, ερμηνευσιμότητα

### Προγνωστική ικανότητα

- Με βάση το **AUC**, το **XGBoost** είναι το καλύτερο (**0.936**).
- **Random Forest** και **XGBoost** έχουν **ίδια** Accuracy/Precision/Recall/F1 στο συγκεκριμένο split, αλλά το XGBoost δίνει ελαφρώς καλύτερο AUC.

### Σταθερότητα / Robustness

- Τα ensemble μοντέλα (Bagging/RF) και το boosting είναι γενικά πιο σταθερά από ένα απλό baseline.
- Το tuning με cross-validation βοηθά ώστε οι υπερπαράμετροι να μην επιλεγούν “τυχαία” από ένα split.

### Ερμηνευσιμότητα

- **Naive Bayes:** πιο εύκολο να εξηγηθεί θεωρητικά (αλλά ισχυρή υπόθεση ανεξαρτησίας).
  - **Bagging / Random Forest:** μέτρια ερμηνευσιμότητα (feature importance/partial dependence αν χρειαστεί).
  - **XGBoost:** υψηλή απόδοση, αλλά πιο “black-box” — ωστόσο η σημαντικότητα χαρακτηριστικών βοηθά στην ερμηνεία.
- 

#### 4.8.2 Σταθερότητα (με βάση CV)

Για Bagging και Random Forest έγινε επιλογή υπερπαραμέτρων με **5-fold CV** στο TRAIN και κρατήθηκε η μέση τιμή AUC καθώς και η διασπορά της (sd\_AUC), ώστε η επιλογή να μην εξαρτάται από ένα μόνο split.

- **Bagging (best):** nbagg=50, depth=5 με CV AUC  $\approx$  **0.914** και sd\_AUC  $\approx$  **0.0109**
- **Random Forest (best):** ntree=500, mtry=2 με CV AUC  $\approx$  **0.932** και sd\_AUC  $\approx$  **0.0118**
- **XGBoost:** χρησιμοποιήθηκε 5-fold CV με **early stopping**, άρα η επιλογή nrounds γίνεται με βάση τη συμπεριφορά στο CV και όχι αυθαίρετα.

**Ερμηνεία:** Τα sd\_AUC είναι σχετικά μικρά, άρα η επίδοση είναι αρκετά **σταθερή** στα folds.

---

### 5 Τελικό συμπέρασμα

Στο συγκεκριμένο πρόβλημα πρόβλεψης καρδιακής νόσου:

- Το **XGBoost** επιτυγχάνει την καλύτερη συνολική ικανότητα διάκρισης (**AUC=0.936**) και κορυφαία μετρικά απόδοσης στο test set.
- Τα **Random Forest** και **Bagging Trees** είναι επίσης πολύ ισχυρά και ανταγωνιστικά, επιβεβαιώνοντας ότι τα ensemble μοντέλα είναι κατάλληλα για αυτό το tabular dataset.
- Ο **Naive Bayes** αποτελεί ισχυρό baseline, αλλά υστερεί έναντι των ensemble/boosting, πιθανότατα λόγω της μη ρεαλιστικής υπόθεσης ανεξαρτησίας των χαρακτηριστικών.