

Ανάλυση Κρατήσεων Ξενοδοχείου με Μεθόδους Ομαδοποίησης

Μάθημα: Μέθοδοι Στατιστικής και Μηχανικής Μάθησης

Εξάμηνο: Χειμερινό 2025–2026

Φοιτητής: Περικλής Παύλου

Αριθμός Μητρώου: p3220158

Τμήμα: Τμήμα Πληροφορικής, ΟΠΑ

Webmail: p3220158@aueb.gr

1. Εισαγωγή

Στην παρούσα εργασία μελετάμε ένα τυχαίο δείγμα κρατήσεων δωματίων από ένα ξενοδοχείο. Για κάθε κράτηση είναι διαθέσιμα διάφορα χαρακτηριστικά της κράτησης (αριθμός ατόμων, διάρκεια διαμονής, χρόνος μεταξύ κράτησης και άφιξης, τιμή, ιστορικό προηγούμενων κρατήσεων κ.ά.), καθώς και το αν η κράτηση τελικά ακυρώθηκε ή όχι. Στόχος είναι να ομαδοποιήσουμε (cluster) τις κρατήσεις **αγνοώντας** την πληροφορία της ακύρωσης κατά τη διαδικασία της ομαδοποίησης, ώστε να εντοπίσουμε ομογενείς τύπους κρατήσεων με παρόμοια χαρακτηριστικά.

Στο πλαίσιο αυτό εφαρμόζουμε τουλάχιστον δύο μεθόδους ομαδοποίησης – συγκεκριμένα k-means και ιεραρχική ομαδοποίηση με μέθοδο Ward – και συγκρίνουμε τα αποτελέσματά τους. Αφού επιλεγεί κατάλληλος αριθμός clusters, περιγράφουμε τις ομάδες που προκύπτουν, εξετάζουμε ποια clusters εμφανίζουν υψηλότερα ποσοστά ακυρώσεων και αξιολογούμε κατά πόσο η διάκριση των ομάδων είναι ικανοποιητική. Τέλος, αιτιολογούμε αναλυτικά την επιλογή και τον μετασχηματισμό των μεταβλητών που χρησιμοποιούνται στο clustering.

2. Περιγραφή δεδομένων

2.1 Δομή και γενικά χαρακτηριστικά του dataset

Τα δεδομένα προέρχονται από αρχείο Excel που περιέχει πληροφορία για κρατήσεις δωματίων. Το αρχικό dataset αποτελείται από **2.000 γραμμές** (κρατήσεις) και **17 στήλες** (μεταβλητές). Η φόρτωση των δεδομένων και ο αρχικός έλεγχος της δομής τους έγινε με τον ακόλουθο κώδικα:

```
library(readxl)

# Read the Excel file with hotel bookings
df <- read_excel("project_cluster.xlsx")

# Basic information: number of rows and columns
dim(df)
```

```
# Structure of the dataset (types of variables)
str(df)

# Number of missing values per column
colSums(is.na(df))
```

Από την εντολή `dim(df)` παρατηρούμε ότι το αρχικό dataset αποτελείται από **2.000 παρατηρήσεις** (κρατήσεις) και **17 μεταβλητές**. Η συνάρτηση `str(df)` δείχνει ότι:

- Το `Booking_ID` είναι συμβολοσειρά (character) και λειτουργεί απλώς ως μοναδικό αναγνωριστικό κάθε κράτησης.
- Οι μεταβλητές `number.of.adults`, `number.of.children`, `number.of.weekend.nights`, `number.of.week.nights`, `lead.time`, `repeated`, `P.C`, `P.not.C`, `special.requests` είναι αριθμητικές (numeric).
- Οι μεταβλητές `type.of.meal`, `room.type`, `market.segment.type`, `average.price`, `date.of.reservation`, `booking.status` εμφανίζονται αρχικά ως χαρακτήρες (character) και θα χρειαστούν κατάλληλη μετατροπή τύπου σε επόμενα βήματα (π.χ. σε factor ή numeric).

Ο έλεγχος των ελλিপών τιμών με `colSums(is.na(df))` δείχνει ότι **δεν υπάρχουν καθόλου missing values** σε καμία μεταβλητή (όλες οι στήλες έχουν άθροισμα 0). Αυτό σημαίνει ότι δεν απαιτείται επιπλέον χειρισμός NA και μπορούμε να προχωρήσουμε απευθείας σε προεπεξεργασία και δημιουργία νέων μεταβλητών.

2.2 Περιγραφή μεταβλητών και βασικά περιγραφικά στατιστικά

Οι αρχικές μεταβλητές που περιέχονται στο αρχείο Excel είναι οι εξής (όπως δίνονται και στην εκφώνηση):

- `Booking_ID`: μοναδικό αναγνωριστικό για κάθε κράτηση.
- `number.of.adults`: αριθμός ενηλίκων που περιλαμβάνονται στην κράτηση.
- `number.of.children`: αριθμός παιδιών που περιλαμβάνονται στην κράτηση.
- `number.of.weekend.nights`: αριθμός διανυκτερεύσεων Σαββατοκύριακου.
- `number.of.week.nights`: αριθμός διανυκτερεύσεων καθημερινών.
- `type.of.meal`: τύπος γεύματος που περιλαμβάνεται στην κράτηση.
- `car.parking.space`: ένδειξη για το αν ζητήθηκε/περιλαμβάνεται θέση στάθμευσης (0/1).
- `room.type`: τύπος δωματίου που έχει γίνει κράτηση.
- `lead.time`: αριθμός ημερών μεταξύ ημερομηνίας κράτησης και ημερομηνίας άφιξης.
- `market.segment.type`: τύπος καναλιού/segment αγοράς (Online, Offline, Corporate κ.λπ.).
- `repeated`: αν ο πελάτης είναι επαναλαμβανόμενος (0/1).
- `P.C`: αριθμός προηγούμενων κρατήσεων που ακυρώθηκαν από τον πελάτη.
- `P.not.C`: αριθμός προηγούμενων κρατήσεων που **δεν** ακυρώθηκαν.
- `average.price`: μέση τιμή που αντιστοιχεί στην κράτηση (αρχικά σε μορφή χαρακτήρα).
- `special.requests`: αριθμός ειδικών αιτημάτων του πελάτη.
- `date.of.reservation`: ημερομηνία πραγματοποίησης της κράτησης.
- `booking.status`: τελικό status της κράτησης (`Canceled` ή `Not_Canceled`).

Για να αποκτήσουμε μια πρώτη εικόνα των βασικών ποσοτικών μεταβλητών, υπολογίσαμε περιγραφικά στατιστικά χρησιμοποιώντας τη συνάρτηση `summary` ως εξής:

```
# Basic descriptive statistics for main numeric-related variables
summary(df[, c("lead.time",
               "average.price",
               "number.of.adults",
               "number.of.children",
               "number.of.weekend.nights",
               "number.of.week.nights",
               "special.requests")])
```

Από τα περιγραφικά στατιστικά προκύπτουν, σε γενικές γραμμές, τα εξής:

- Lead time (lead.time) Οι τιμές κυμαίνονται από πολύ “last-minute” κρατήσεις (0 ημέρες) μέχρι κρατήσεις που γίνονται πολλούς μήνες πριν την άφιξη. Η κατανομή είναι αρκετά ανισομερής, με πολλές τιμές σε ενδιάμεσους ορίζοντες (περίπου 1–4 μήνες πριν την άφιξη).
- Μέση τιμή κράτησης (average.price) Η μεταβλητή εμφανίζεται αρχικά ως χαρακτήρας και στη συνέχεια μετατρέπεται σε αριθμητική (βλ. Ενότητα 3). Μετά τη μετατροπή, οι τιμές κυμαίνονται σε μια ρεαλιστική κλίμακα τιμών δωματίου, με τη μεγάλη πλειονότητα των κρατήσεων να συγκεντρώνεται σε μια μεσαία ζώνη τιμών και λίγες ακραίες (πολύ χαμηλές ή πολύ υψηλές) τιμές.
- Αριθμός ατόμων (number.of.adults, number.of.children) Οι περισσότερες κρατήσεις αφορούν 2 ενήλικες, ενώ τα παιδιά είναι συνήθως 0. Αυτό υποδεικνύει ότι η “τυπική” κράτηση αφορά ζευγάρια ή μικρές παρέες χωρίς παιδιά.
- Διανυκτερεύσεις (number.of.weekend.nights, number.of.week.nights) Ο συνολικός αριθμός διανυκτερεύσεων προκύπτει από το άθροισμα των διανυκτερεύσεων Σαββατοκύριακου και καθημερινών. Οι περισσότερες κρατήσεις αντιστοιχούν σε σύντομη διαμονή, περίπου 2–4 νύχτες.
- Ειδικά αιτήματα (special.requests) Σημαντικό μέρος των κρατήσεων δεν έχει κανένα ειδικό αίτημα (τιμή 0), ενώ ένα μικρότερο ποσοστό περιλαμβάνει 1 ή περισσότερα ειδικά αιτήματα, γεγονός που μπορεί να συνδέεται με πιο “απαιτητικούς” πελάτες.
- Η μεταβλητή booking.status δεν θα χρησιμοποιηθεί απευθείας στον αλγόριθμο ομαδοποίησης (ώστε το clustering να γίνει “τυφλά” ως προς το αν μια κράτηση ακυρώνεται ή όχι), αλλά θα αξιοποιηθεί αργότερα για την ερμηνεία των clusters, δηλαδή για να εξετάσουμε ποια ομάδες κρατήσεων παρουσιάζουν υψηλότερα ποσοστά ακύρωσης.

3. Προεπεξεργασία και δημιουργία νέων μεταβλητών

Η ενότητα αυτή περιγράφει τα βήματα προεπεξεργασίας που εφαρμόστηκαν στα αρχικά δεδομένα, καθώς και τις νέες μεταβλητές που δημιουργήθηκαν πριν την εφαρμογή των μεθόδων ομαδοποίησης. Παράλληλα, αιτιολογείται η τελική επιλογή των μεταβλητών που χρησιμοποιήθηκαν στο clustering, όπως ζητείται και στο σκέλος (Γ) της εκφώνησης.

3.1 Καθαρισμός δεδομένων και μετατροπή τύπων

Αρχικά, αφαιρέθηκαν ορισμένες μεταβλητές που κρίθηκαν λιγότερο σχετικές με τον στόχο της εργασίας. Συγκεκριμένα, οι μεταβλητές `Booking_ID`, `type.of.meal`, `car.parking.space` και `room.type` περιγράφουν

κυρίως τον τύπο του πακέτου/δωματίου και όχι τόσο τη συμπεριφορά του πελάτη ως προς το πότε, για πόσο και με τι "προφίλ" κάνει κράτηση. Για να απλοποιηθεί το μοντέλο και να εστιάσουμε σε πιο "συμπεριφορικές" πτυχές της κράτησης, οι στήλες αυτές αφαιρέθηκαν από το dataset.

Παράλληλα, έγιναν βασικές μετατροπές τύπων:

- Η `average.price` μετατράπηκε από χαρακτήρα (character) σε αριθμητική μεταβλητή (numeric), ώστε να μπορεί να χρησιμοποιηθεί σε υπολογισμούς και να συμμετέχει στο clustering.
- Οι μεταβλητές `market.segment.type`, `booking.status` και `repeated` μετατράπηκαν σε παραγοντικές (factor), καθώς πρόκειται για κατηγορικές πληροφορίες (τύπος segment, τελικό status κράτησης και ένδειξη επαναλαμβανόμενου πελάτη αντίστοιχα).

Ο αντίστοιχος κώδικας R είναι ο ακόλουθος:

```
library(dplyr)

df <- df %>%
  # Drop variables that are not used in the clustering analysis
  select(
    -type.of.meal,
    -car.parking.space,
    -room.type
  ) %>%
  # Convert selected variables to appropriate types
  mutate(
    market.segment.type = as.factor(market.segment.type),
    booking.status       = as.factor(booking.status),
    repeated             = as.factor(repeated),
    average.price        = as.numeric(average.price)
  )
```

Με αυτό τον τρόπο, το dataset παραμένει καθαρό, χωρίς ελλιπείς τιμές, και όλες οι μεταβλητές που θα χρησιμοποιηθούν στη συνέχεια έχουν κατάλληλους τύπους δεδομένων.

3.2 Δημιουργία νέων μεταβλητών (feature engineering)

Στη συνέχεια, δημιουργήθηκαν νέες μεταβλητές που συνοψίζουν σημαντικές πτυχές της κράτησης και του ιστορικού του πελάτη. Οι μεταβλητές αυτές βασίζονται σε συνδυασμούς των αρχικών πεδίων:

- `persons = number.of.adults + number.of.children` Συνολικός αριθμός ατόμων (ενήλικες + παιδιά) ανά κράτηση. Η μεταβλητή αυτή αποτυπώνει το μέγεθος της παρέας/οικογένειας και επιτρέπει τη διάκριση, για παράδειγμα, μεταξύ μεμονωμένων επισκεπτών, ζευγαριών και μεγαλύτερων ομάδων.
- `nights = number.of.weekend.nights + number.of.week.nights` Συνολικός αριθμός διανυκτερεύσεων ανά κράτηση. Η μεταβλητή αυτή συνοψίζει τη διάρκεια της διαμονής και βοηθά στην ανάδειξη clusters με σύντομες έναντι πιο μακροχρόνιων κρατήσεων.
- `prev_total = P.C + P.not.C` Συνολικός αριθμός προηγούμενων κρατήσεων (ανεξαρτήτως αν ακυρώθηκαν ή όχι).

- `has_prev_booking = ifelse(prev_total > 0, 1, 0)` Δυαδικός δείκτης που παίρνει τιμή 1 αν ο πελάτης έχει ιστορικό προηγούμενων κρατήσεων και 0 αν πρόκειται για "νέο" πελάτη.
- `has_prev_cancel = ifelse(P.C > 0, 1, 0)` Δυαδικός δείκτης που παίρνει τιμή 1 αν ο πελάτης έχει ακυρώσει τουλάχιστον μία προηγούμενη κράτηση. Η μεταβλητή αυτή επιχειρεί να κωδικοποιήσει αν ο πελάτης έχει "ιστορικό ακυρώσεων".

Ο κώδικας που υλοποιεί τα παραπάνω είναι:

```
df <- df %>%
  mutate(
    # Total number of guests (adults + children)
    persons = number.of.adults + number.of.children,
    # Total number of nights (weekend + weekdays)
    nights = number.of.weekend.nights + number.of.week.nights,
    # Total number of previous bookings
    prev_total = P.C + P.not.C,
    # Indicator of having any previous booking
    has_prev_booking = ifelse(prev_total > 0, 1, 0),
    # Indicator of having any previous cancellation
    has_prev_cancel = ifelse(P.C > 0, 1, 0)
  )
```

Οι νέες αυτές μεταβλητές είναι πιο "συνοπτικές" και ερμηνεύσιμες και θα χρησιμοποιηθούν άμεσα στη διαδικασία ομαδοποίησης.

3.3 Επιλογή μεταβλητών για το clustering

Στο επόμενο βήμα, ήταν απαραίτητο να επιλεγεί ένα σύνολο μεταβλητών που θα χρησιμοποιηθούν ως βάση για το clustering. Ο στόχος ήταν οι μεταβλητές:

- να περιγράφουν **συμπεριφορά κράτησης** (π.χ. διάρκεια, χρονικός ορίζοντας, τιμή),
- να κωδικοποιούν **ιστορικό σχέσης με το ξενοδοχείο** (προηγούμενες κρατήσεις/ακυρώσεις),
- και να είναι επαρκώς ερμηνεύσιμες για να περιγραφούν αργότερα τα clusters.

Με βάση τα παραπάνω κριτήρια, επιλέχθηκαν οι εξής έξι μεταβλητές ως τελικά χαρακτηριστικά για το clustering:

- `persons` (μέγεθος παρέας),
- `nights` (διάρκεια διαμονής),
- `lead.time` (πόσο νωρίς γίνεται η κράτηση),
- `average.price` (επίπεδο τιμής κράτησης),
- `has_prev_booking` (αν ο πελάτης έχει προηγούμενες κρατήσεις),
- `has_prev_cancel` (αν ο πελάτης έχει ιστορικό ακυρώσεων).

Η επιλογή αυτή δεν έγινε "με το μάτι", αλλά στηρίχθηκε και σε εμπειρική αξιολόγηση της ποιότητας των clusters μέσω του **μέσου δείκτη silhouette** για διαφορετικούς συνδυασμούς μεταβλητών. Ενδεικτικά:

- Όταν χρησιμοποιήθηκαν μόνο βασικές συμπεριφορικές μεταβλητές, όπως `persons`, `nights`, `lead.time`, `average.price`, οι τιμές του μέσου silhouette για k από 2 έως 8 κυμαίνονταν περίπου

στο **0.26–0.28**, υποδηλώνοντας κακό διαχωρισμό των ομάδων.

- Η προσθήκη επιπλέον μεταβλητών, όπως δείκτες για ειδικά αιτήματα (**special.requests** / δυαδικές εκδοχές), δεν βελτίωσε ουσιαστικά την εικόνα: ο μέσος silhouette παρέμεινε σχετικά χαμηλός.
- Αντίθετα, όταν περιοριστήκαμε στις έξι μεταβλητές **persons**, **nights**, **lead.time**, **average.price**, **has_prev_booking**, **has_prev_cancel**, η λύση με **k = 2 clusters** έδωσε μέσο silhouette περίπου **0.71**, που αντιστοιχεί σε πολύ καλή ποιότητα ομαδοποίησης και “καθαρό” διαχωρισμό μεταξύ των ομάδων.

Έτσι, η τελική επιλογή των χαρακτηριστικών βασίζεται τόσο στη θεωρητική ερμηνευσιμότητα (μέγεθος παρέας, διάρκεια, τιμή, ιστορικό πελάτη), όσο και σε εμπειρική τεκμηρίωση ότι οι συγκεκριμένες μεταβλητές οδηγούν σε σαφέστερα και πιο διακριτά clusters σε σχέση με εναλλακτικούς συνδυασμούς.

Ο κώδικας που ορίζει το τελικό σύνολο μεταβλητών και το αντίστοιχο numeric dataset είναι:

```
# Final set of variables used for clustering
final_vars <- c(
  "persons",
  "nights",
  "lead.time",
  "average.price",
  "has_prev_booking",
  "has_prev_cancel"
)

# Numeric dataset for clustering analysis
df_num <- df[, final_vars]
```

Τέλος, αξίζει να σημειωθεί ότι δοκιμάστηκαν και άλλες μεταβλητές σε ενδιάμεσα πειραματικά μοντέλα, όπως το **market.segment.type**, τα **special.requests**, το **repeated** και η ακριβής **date.of.reservation**. Σε αυτές τις δοκιμές ο μέσος δείκτης silhouette για ($k \geq 2$) δεν βελτιώθηκε ουσιαστικά (σε πολλές περιπτώσεις παρέμενε γύρω στο 0.28–0.30) και σε ορισμένες περιπτώσεις η ποιότητα των clusters υποβαθμιζόταν ελαφρώς. Επιπλέον, κάποιες μεταβλητές, όπως η ημερομηνία κράτησης ή ο τύπος του καναλιού (**market.segment.type**), κρίθηκαν λιγότερο κεντρικές για τον βασικό σκοπό της εργασίας, που είναι η ομαδοποίηση με βάση το «προφίλ» και το ιστορικό συμπεριφοράς του πελάτη (πλήθος ατόμων, διάρκεια διαμονής, χρονικός ορίζοντας, επίπεδο τιμής, προηγούμενες κρατήσεις/ακυρώσεις). Για τους λόγους αυτούς επιλέχθηκε τελικά ένα πιο συμπαγές και ερμηνεύσιμο σύνολο έξι μεταβλητών, το οποίο συνδυάζει χαρακτηριστικά κράτησης και ιστορικό σχέσης με το ξενοδοχείο και οδηγεί σε σαφώς καλύτερη ποιότητα ομαδοποίησης (mean silhouette ≈ 0.72 για ($k = 2$)).

4. Επιλογή αριθμού clusters

Σε αυτή την ενότητα περιγράφουμε πώς επιλέξαμε τον αριθμό clusters (k) για τον αλγόριθμο k-means, χρησιμοποιώντας τρεις τυπικές μεθόδους(από τις διαφάνειες):

- το **Elbow plot** (εντός-ομάδας άθροισμα τετραγώνων – WSS),
- τον **μέσο δείκτη silhouette**,
- και το **Gap statistic**.

Η ανάλυση γίνεται πάνω στο τελικό σύνολο μεταβλητών που επιλέχθηκε στην Ενότητα 3.3: `persons`, `nights`, `lead.time`, `average.price`, `has_prev_booking`, `has_prev_cancel`.

4.1 Προετοιμασία δεδομένων και επιλογή scaler

Για την εφαρμογή των μεθόδων επιλογής αριθμού clusters (Elbow, Silhouette, Gap) χρησιμοποιούμε το τελικό σύνολο μεταβλητών `persons`, `nights`, `lead.time`, `average.price`, `has_prev_booking`, `has_prev_cancel`. Από το αρχικό data frame κρατάμε μόνο αυτές τις στήλες και δημιουργούμε ένα numeric dataset:

```
final_vars <- c(
  "persons",
  "nights",
  "lead.time",
  "average.price",
  "has_prev_booking",
  "has_prev_cancel"
)

df_num <- df[, final_vars]
df_scaled <- scale(df_num) # standardization (mean 0, sd 1)
```

Χρησιμοποιούμε standardization με τη συνάρτηση `scale`, ώστε όλες οι μεταβλητές να έχουν συγκρίσιμη κλίμακα: μέση τιμή περίπου 0 και τυπική απόκλιση 1. Αυτό είναι ιδιαίτερα σημαντικό επειδή το k-means και η ιεραρχική ομαδοποίηση (Ward) βασίζονται σε Ευκλείδειες αποστάσεις και variance-based κριτήρια· χωρίς κανονικοποίηση, οι μεταβλητές με μεγάλο εύρος (όπως `lead.time` και `average.price`) θα κυριαρχούσαν στον υπολογισμό των αποστάσεων, “σκεπάζοντας” πληροφορία από μεταβλητές όπως `persons`, `nights` και τους δυαδικούς δείκτες ιστορικού (`has_prev_*`). Με το standard scaling όλες συνεισφέρουν πιο ισότιμα και τα κριτήρια (Elbow, Silhouette, Gap) γίνονται πιο αξιόπιστα.

4.2 Επιλογή k με τη μέθοδο Elbow

Η μέθοδος Elbow εξετάζει πώς μειώνεται το εντός-ομάδας άθροισμα τετραγώνων (Total WSS) καθώς αυξάνεται ο αριθμός clusters (k). Για πολύ μικρό (k) το WSS είναι μεγάλο (κακή προσαρμογή), ενώ καθώς αυξάνουμε το (k) το WSS μειώνεται. Συνήθως αναζητούμε ένα σημείο όπου η μείωση “επιβραδύνεται” αισθητά· αυτός ο “αγκώνας” θεωρείται καλή υποψήφια τιμή για το (k).

Ο παρακάτω κώδικας υπολογίζει και απεικονίζει το Elbow plot για ($k = 1, \dots, 8$), χρησιμοποιώντας το κανονικοποιημένο dataset `df_scaled`:

```
set.seed(123) # for reproducibility

fviz_nbclust(
  df_scaled,
  kmeans,
  method = "wss"
) +
  ggtitle("Elbow plot for k-means") +
```


```
xlab("Number of clusters (k)") +  
ylab("Total within-clusters sum of squares") +  
theme_gray()
```

4.2 Επιλογή αριθμού clusters με τη μέθοδο Elbow

Η μέθοδος **Elbow** εξετάζει πώς μειώνεται το συνολικό εντός-ομάδας άθροισμα τετραγώνων (Total within-cluster sum of squares, WSS) όταν αυξάνουμε τον αριθμό των clusters (k). Για κάθε τιμή (k) εφαρμόζουμε k -means στα κανονικοποιημένα δεδομένα `df_scaled` και καταγράφουμε το αντίστοιχο WSS:

```
set.seed(123) # Reproducibility  
  
fviz_nbclust(  
  df_scaled,  
  kmeans,  
  method = "wss"  
) +  
  ggtitle("Elbow Plot (WSS vs. Number of Clusters)") +  
  xlab("Number of clusters (k)") +  
  ylab("Total within-cluster sum of squares (WSS)") +  
  theme_gray()
```

Στο Elbow Plot παρατηρούμε μια πολύ έντονη μείωση του WSS όταν περνάμε από ($k = 1$) σε ($k = 2$), και μικρότερη αλλά ακόμη αισθητή μείωση για ($k = 3$). Για ($k = 3$) η καμπύλη αρχίζει να "ισιώνει" και η επιπλέον μείωση του WSS είναι σχετικά μικρή σε σχέση με την αύξηση της πολυπλοκότητας του μοντέλου (περισσότερα clusters). Με βάση μόνο τη μέθοδο Elbow, το σημείο κάμψης φαίνεται να βρίσκεται κάπου στο διάστημα ($k \in \{2, 3\}$), χωρίς όμως να προκύπτει απολύτως ξεκάθαρη μία μόνο τιμή. Η τελική επιλογή του (k) θα γίνει αφού συνεκτιμήσουμε και τα αποτελέσματα του δείκτη Silhouette (Ενότητα 4.3) και του Gap statistic (Ενότητα 4.4).



4.3 Επιλογή k με βάση τον δείκτη Silhouette

Ο δείκτης **silhouette** μετρά πόσο καλά ταιριάζει κάθε παρατήρηση στο cluster της σε σχέση με τα γειτονικά clusters. Οι τιμές κυμαίνονται στο $[-1, 1]$: τιμές κοντά στο 1 δείχνουν ότι οι παρατηρήσεις είναι


καλά χωρισμένες, τιμές γύρω στο 0 υποδηλώνουν επικάλυψη μεταξύ clusters, ενώ αρνητικές τιμές σημαίνουν λανθασμένη ανάθεση.

Ο παρακάτω κώδικας υπολογίζει τον μέσο δείκτη silhouette για ($k = 2, \dots, 8$), χρησιμοποιώντας τα κανονικοποιημένα δεδομένα `df_scaled`:

```
set.seed(123) # ensure reproducibility

fviz_nbclust(
  df_scaled,
  kmeans,
  method = "silhouette"
) +
  ggtitle("Mean Silhouette Index vs. Number of Clusters") +
  xlab("Number of clusters (k)") +
  ylab("Mean silhouette index") +
  theme_gray()
```

Από το γράφημα Mean Silhouette Index vs. Number of Clusters παρατηρούμε ότι ο μέσος δείκτης silhouette είναι μέγιστος για $k=2$ (περίπου 0.72), ενώ για μεγαλύτερες τιμές k πέφτει σε επίπεδα γύρω στο 0.28–0.31. Αυτό σημαίνει ότι όταν χωρίζουμε τις κρατήσεις σε δύο ομάδες, οι παρατηρήσεις είναι πολύ πιο “συμπαγείς” και καλά διαχωρισμένες μεταξύ τους, ενώ η δημιουργία επιπλέον clusters δεν βελτιώνει ουσιαστικά τη διακριτότητα των ομάδων. Συνεπώς, η μέθοδος silhouette ενισχύει ισχυρά την επιλογή του $k=2$ ως βέλτιστου αριθμού clusters.



4.4 Επιλογή k με το Gap Statistic

Το **Gap statistic** συγκρίνει την τιμή του εντός-ομάδας WSS που προκύπτει από το πραγματικό dataset με την αντίστοιχη τιμή που θα περιμέναμε αν τα δεδομένα ήταν εντελώς “χωρίς δομή” (ομοιόμορφα καταναμημένα σε ένα ορθογώνιο). Όσο μεγαλύτερο είναι το Gap, τόσο περισσότερο “κερδίζουμε” σε σχέση με ένα τυχαίο μοίρασμα των σημείων και άρα τόσο πιο “ουσιαστικό” θεωρείται το clustering.


Ο παρακάτω κώδικας υπολογίζει το Gap statistic για ($k = 1, \dots, 8$) στα κανονικοποιημένα δεδομένα `df_scaled` και παράγει το αντίστοιχο γράφημα:

```
set.seed(123) # Reproducibility

gap_stat <- clusGap(
  df_scaled,
  FUN      = kmeans,
  nstart    = 25,
  K.max     = 8,
  B        = 50
)

fviz_gap_stat(gap_stat) +
  ggtitle("Gap Statistic for k-means") +
  xlab("Number of clusters (k)") +
  ylab("Gap statistic") +
  theme_gray()
```

Στο γράφημα του Gap statistic παρατηρούμε ότι η τιμή του Gap αυξάνεται σχετικά ομαλά καθώς μεγαλώνει το k χωρίς να εμφανίζεται ένα πολύ ξεκάθαρο μέγιστο σε κάποια ενδιάμεση τιμή. Ο τυπικός κανόνας επιλογής (πρώτο k για το οποίο το Gap δεν αυξάνεται σημαντικά σε σχέση με το $k+1$) οδηγεί ουσιαστικά σε πολύ μικρές τιμές k . Αν περιοριστούμε σε $k \geq 2$ (ώστε να έχουμε τουλάχιστον δύο ομάδες ενδιαφέροντος), το Gap statistic δεν ξεχωρίζει έντονα κάποια συγκεκριμένη τιμή, αλλά υποστηρίζει την ιδέα ότι λίγα clusters (2–3) αρκούν για να περιγράψουν τη βασική δομή των δεδομένων, καθώς η αύξηση του k πέρα από αυτές τις τιμές προσφέρει μόνο μικρή βελτίωση στο Gap.



4.5 Συνολική επιλογή αριθμού clusters

Συνοψίζοντας τα αποτελέσματα των τριών κριτηρίων:

- Η μέθοδος **Elbow** (Ενότητα 4.2) δείχνει μια έντονη κάμψη της καμπύλης WSS στη μετάβαση από ($k = 1$) σε ($k = 2$) και μικρότερη βελτίωση για ($k = 3$). Πέρα από αυτά η επιπλέον μείωση του WSS είναι σχετικά περιορισμένη, υποδεικνύοντας ότι 2–3 clusters είναι επαρκή.
- Ο δείκτης **Silhouette** (Ενότητα 4.3) παρουσιάζει ξεκάθαρο μέγιστο για ($k = 2$) (mean silhouette ≈ 0.72), ενώ όλες οι υπόλοιπες επιλογές ($k = 3$ με 8) έχουν σημαντικά χαμηλότερες τιμές (≈ 0.28 – 0.31). Άρα, από άποψη συνοχής και διαχωρισιμότητας των ομάδων, το ($k = 2$) είναι σαφώς προτιμότερο.
- Το **Gap statistic** (Ενότητα 4.4) δεν εντοπίζει ένα απόλυτα καθαρό εσωτερικό μέγιστο όμως δείχνει ότι η αύξηση του (k) πέρα από μικρές τιμές αποφέρει σχετικά μικρό πρόσθετο όφελος, κάτι που

συμφωνεί με την ιδέα ότι λίγα clusters (2–3) περιγράφουν ικανοποιητικά τη δομή των δεδομένων.

Λαμβάνοντας υπόψη όλα τα παραπάνω, και ειδικά το πολύ υψηλότερο silhouette για ($k = 2$) σε σχέση με τα υπόλοιπα (k), επιλέγουμε τελικά να δουλέψουμε με **δύο clusters ($k = 2$)**. Η επιλογή αυτή ισορροπεί ανάμεσα στην απλότητα του μοντέλου και την ποιότητα διαχωρισμού των κρατήσεων, και θα χρησιμοποιηθεί ως βάση για την ερμηνεία των ομάδων και τη σύγκριση των δύο μεθόδων ομαδοποίησης (k -means και ιεραρχική) στις επόμενες ενότητες.

5. Εφαρμογή μεθόδων ομαδοποίησης

Σε αυτή την ενότητα εφαρμόζουμε τις δύο μεθόδους ομαδοποίησης που ζητά η εκφώνηση (k -means και ιεραρχική ομαδοποίηση) πάνω στο κανονικοποιημένο dataset `df_scaled`, χρησιμοποιώντας τον αριθμό clusters ($k = 2$) που προέκυψε από την ανάλυση της Ενότητας 4. Στόχος είναι να περιγράψουμε τις ομάδες που προκύπτουν, να εξετάσουμε τη σχέση τους με τις ακυρώσεις κρατήσεων (`booking.status`) και να αξιολογήσουμε την ποιότητα των clusters.

5.1 k -means clustering ($k = 2$)

Η πρώτη μέθοδος που εφαρμόζουμε είναι ο αλγόριθμος **k -means**, με ($k = 2$) clusters και αρχικοποίηση με πολλαπλά τυχαία ξεκινήματα (`nstart = 25`) για μεγαλύτερη σταθερότητα των αποτελεσμάτων:

```
set.seed(123) # Reproducibility

# Run k-means with k = 2 on the standardized data
km2 <- kmeans(df_scaled, centers = 2, nstart = 25)

# Attach cluster labels back to the original data frame
df$cluster_kmeans <- factor(km2$cluster)
```

Για να αξιολογήσουμε την ποιότητα της λύσης, υπολογίζουμε τον μέσο δείκτη silhouette:

```
# Distance matrix on standardized data
dist_mat <- dist(df_scaled)

# Silhouette analysis for k-means solution
sil_km2 <- silhouette(as.integer(df$cluster_kmeans), dist_mat)
mean_sil <- summary(sil_km2)$avg.width
mean_sil
```


Ο μέσος δείκτης silhouette είναι περίπου 0.72, τιμή που θεωρείται πολύ καλή και δείχνει ότι τα δύο clusters που σχηματίζονται είναι σχετικά συμπαγή και καλά διαχωρισμένα μεταξύ τους.

Οπτική απεικόνιση των clusters(προαιρετικό)

Για να αποκτήσουμε μια πιο διαισθητική εικόνα του διαχωρισμού, προβάλλουμε τα δεδομένα σε δύο κύριες συνιστώσες (PCA) και χρωματίζουμε τα σημεία ανάλογα με το cluster στο οποίο ανήκουν:

```
fviz_cluster(  
  km2,  
  data = df_scaled,  
  geom = "point",  
  ellipse.type = "norm",  
  show.clust.cent = TRUE,  
  main = "k-means clustering (k = 2)"  
)
```

Στο γράφημα k-means clustering (k = 2) φαίνεται ότι τα δύο clusters καταλαμβάνουν σχετικά διακριτές περιοχές στο επίπεδο των δύο πρώτων κύριων συνιστωσών, επιβεβαιώνοντας οπτικά αυτό που ήδη είδαμε μέσω του silhouette.



Περιγραφή των δύο clusters (προφίλ)

Για να περιγράψουμε τα clusters, υπολογίζουμε βασικά περιγραφικά μεγέθη ανά ομάδα:

```
km_profiles <- df %>%  
  group_by(cluster_kmeans) %>%  
  summarise(  
    n = n(),  
    mean_persons = mean(persons),  
    mean_nights = mean(nights),  
    mean_lead = mean(lead.time),  
    mean_price = mean(average.price),  
    mean_prev_book = mean(has_prev_booking),  
    mean_prev_cancel = mean(has_prev_cancel)  
  )  
km_profiles
```

Σε γενικές γραμμές, τα προφίλ των δύο clusters μπορούν να περιγραφούν ως εξής:

Cluster 1 (μεγάλη πλειονότητα των κρατήσεων)

- Περίπου 2 άτομα ανά κράτηση κατά μέσο όρο.

- 3 νύχτες διαμονής κατά μέσο όρο.
- Μεγαλύτερο lead time, γύρω στις ~85 ημέρες: οι κρατήσεις γίνονται αρκετό καιρό πριν την άφιξη.
- Μεσαίο επίπεδο τιμής (average.price γύρω στα ~100–105).
- Σχεδόν κανένα ιστορικό προηγούμενων κρατήσεων/ακυρώσεων (mean_prev_book ≈ 0 , mean_prev_cancel ≈ 0). Πρόκειται, λοιπόν, για “τυπικούς” πελάτες χωρίς προηγούμενη σχέση με το ξενοδοχείο, που κλείνουν εγκαίρως και για μεσαία διάρκεια διαμονής.

Cluster 2 (μικρή αλλά πολύ ιδιαίτερη ομάδα)

- Λίγο πάνω από 1 άτομο ανά κράτηση (συχνά single).
- Μικρότερη διάρκεια διαμονής (περίπου 2 νύχτες).
- Πολύ μικρό lead time (~4 ημέρες): κρατήσεις “τελευταίας στιγμής”.
- Χαμηλότερες τιμές (average.price σε σαφώς χαμηλότερα επίπεδα).
- Σχεδόν όλοι έχουν προηγούμενες κρατήσεις και σημαντικό ποσοστό έχει ιστορικό ακύρωσης (mean_prev_book κοντά στο 1, mean_prev_cancel υψηλότερο από το cluster 1). Αυτό το cluster αντιστοιχεί σε “γνωστούς” πελάτες, που κλείνουν συχνά τελευταία στιγμή, για λίγες νύχτες και σε χαμηλότερη τιμή.

Σχέση clusters με τις ακυρώσεις

Για να απαντήσουμε στο ερώτημα “ποια clusters έχουν τις περισσότερες ακυρώσεις;”, υπολογίζουμε το ποσοστό των Canceled και Not_Canceled κρατήσεων μέσα σε κάθε cluster:


```
km_cancel <- df %>%
  group_by(cluster_kmeans, booking.status) %>%
  summarise(n = n(), .groups = "drop") %>%
  group_by(cluster_kmeans) %>%
  mutate(prop = n / sum(n))
```

```
km_cancel
```

και το απεικονίζουμε με ένα stacked barplot:

```
ggplot(km_cancel,
  aes(x = cluster_kmeans, y = prop, fill = booking.status)) +
  geom_col(position = "fill") +
  scale_y_continuous(labels = scales::percent) +
  labs(
    title = "Cancellation rates by cluster - k-means (k = 2)",
    x = "Cluster (k-means)",
    y = "Proportion within cluster",
    fill = "Booking status"
```

```
) +  
theme_gray()
```



Από το γράφημα Cancellation rates by cluster – k-means και τον πίνακα `km_cancel` προκύπτει ότι:

- Στο Cluster 1 περίπου 35% των κρατήσεων είναι Canceled και 65% είναι Not_Canceled.
- Στο Cluster 2 όλες οι κρατήσεις είναι Not_Canceled (ποσοστό ακύρωσης ~0%).

Άρα, παρότι το Cluster 2 εμφανίζει πελάτες με ιστορικό κρατήσεων και συχνά με προηγούμενες ακυρώσεις, στις τρέχουσες κρατήσεις που υπάρχουν στο dataset το συγκεκριμένο cluster έχει μηδενικές ακυρώσεις, ενώ το Cluster 1 συγκεντρώνει όλες τις ακυρωμένες κρατήσεις. Αυτό είναι ένα πολύ ενδιαφέρον εύρημα που θα σχολιάσουμε συγκριτικά και με τη δεύτερη μέθοδο (ιεραρχική ομαδοποίηση) στην επόμενη υποενότητα.

5.2 Ιεραρχική ομαδοποίηση (Ward, k = 2)

Ως δεύτερη μέθοδο ομαδοποίησης εφαρμόζουμε **ιεραρχικό clustering** με μέθοδο Ward (`ward.D2`) και Ευκλείδειες αποστάσεις πάνω στα ίδια κανονικοποιημένα δεδομένα `df_scaled`. Η μέθοδος Ward είναι ιδιαίτερα κατάλληλη όταν μας ενδιαφέρει η δημιουργία συμπαγών, "σφαιρικών" clusters, παρόμοια με τον k-means.

```
# Hierarchical clustering with Ward's method  
hc <- hclust(dist_mat, method = "ward.D2")  
  
# Dendrogram  
plot(hc,  
      labels = FALSE,  
      main = "Hierarchical clustering dendrogram (Ward.D2)",  
      xlab = "",  
      sub = "")  
  
# Highlight the 2-cluster solution  
rect.hclust(hc, k = 2, border = "red")
```


5.2 Ιεραρχική ομαδοποίηση (Ward, k = 2)

Ως δεύτερη μέθοδο ομαδοποίησης εφαρμόζουμε **ιεραρχικό clustering** με μέθοδο Ward (`ward.D2`) και Ευκλείδειες αποστάσεις πάνω στα ίδια κανονικοποιημένα δεδομένα `df_scaled`. Η μέθοδος Ward είναι ιδιαίτερα κατάλληλη όταν μας ενδιαφέρει η δημιουργία συμπαγών, "σφαιρικών" clusters, παρόμοια με τον k-means.

```
# Hierarchical clustering with Ward's method
hc <- hclust(dist_mat, method = "ward.D2")

# Dendrogram
plot(hc,
     labels = FALSE,
     main = "Hierarchical clustering dendrogram (Ward.D2)",
     xlab = "",
     sub = "")

# Highlight the 2-cluster solution
rect.hclust(hc, k = 2, border = "red")
```



Στο πλήρες δενδρόγραμμα παρατηρούμε ότι το dataset χωρίζεται προοδευτικά σε υπο-ομάδες, ενώ με την επιλογή $k=2$ κόβουμε το δέντρο σε δύο κύριους κλάδους (κόκκινα ορθογώνια). Οι δύο αυτοί κλάδοι αντιστοιχούν στη λύση των 2 clusters με τη μέθοδο Ward.

Ανάθεση παρατηρήσεων σε 2 clusters

Για να πάρουμε τη 2-ομαδική λύση από το δενδρόγραμμα, χρησιμοποιούμε την `cutree` με `k=2` και αποθηκεύουμε τα labels στο data frame:

```
# Cut the dendrogram into 2 clusters
hc_clusters2 <- cutree(hc, k = 2)

# Attach hierarchical cluster labels
df$cluster_hclust <- factor(hc_clusters2)

# Cluster sizes
table(df$cluster_hclust)
```

Η ιεραρχική ομαδοποίηση με Ward δίνει ακριβώς τα ίδια μεγέθη ομάδων με τον k-means: ένα πολύ μεγάλο cluster με 1.952 κρατήσεις και ένα μικρό cluster με 48 κρατήσεις.

Υπολογίζουμε επίσης τον μέσο δείκτη silhouette για τη λύση των 2 clusters:

```
sil_hc2 <- silhouette(hc_clusters2, dist_mat)
mean_sil <- summary(sil_hc2)$avg.width
mean_sil
```

Ο μέσος δείκτης silhouette είναι και εδώ περίπου 0.72, δηλαδή πρακτικά ταυτόσημος με αυτόν του k-means. Αυτό σημαίνει ότι, με βάση τις αποστάσεις και τη λύση των 2 clusters, οι δύο μέθοδοι παράγουν ποιοτικά ισοδύναμο διαχωρισμό.

Προφίλ των clusters (ιεραρχική ομαδοποίηση)

Για τη σύγκριση με τον k-means, υπολογίζουμε τα ίδια περιγραφικά μεγέθη ανά cluster:

```
hc_profiles <- df %>%
  group_by(cluster_hclust) %>%
  summarise(
    n = n(),
    mean_persons = mean(persons),
    mean_nights = mean(nights),
    mean_lead = mean(lead.time),
    mean_price = mean(average.price),
    mean_prev_book = mean(has_prev_booking),
    mean_prev_cancel = mean(has_prev_cancel)
  )
hc_profiles
```

Τα προφίλ που προκύπτουν είναι ουσιαστικά ίδια με αυτά του k-means:

- Ένα μεγάλο cluster με πελάτες 2 ατόμων, διαμονή ~3 νύχτες, μεγαλύτερο lead time και μεσαίες τιμές, χωρίς σημαντικό ιστορικό κρατήσεων/ακυρώσεων.
- Ένα μικρό cluster με "γνωστούς" πελάτες, μικρότερο μέγεθος παρέας, μικρό lead time, χαμηλότερες τιμές και έντονο ιστορικό προηγούμενων κρατήσεων.

Ποσοστά ακυρώσεων ανά cluster (ιεραρχική)


Τέλος, εξετάζουμε πώς κατανέμονται οι ακυρώσεις στα clusters της ιεραρχικής ομαδοποίησης:

```
hc_cancel <- df %>%
  group_by(cluster_hclust, booking.status) %>%
  summarise(n = n(), .groups = "drop") %>%
  group_by(cluster_hclust) %>%
  mutate(prop = n / sum(n))

hc_cancel

και οπτικοποιούμε τα ποσοστά:

ggplot(hc_cancel,
  aes(x = cluster_hclust, y = prop, fill = booking.status)) +
  geom_col(position = "fill") +
  scale_y_continuous(labels = scales::percent) +
  labs(
    title = "Cancellation rates by cluster - Hierarchical (Ward, k = 2)",
    x = "Cluster (hierarchical)",
    y = "Proportion within cluster",
    fill = "Booking status"
  ) +
  theme_gray()
```



Τα ποσοστά ακυρώσεων ανά cluster είναι ίδια με εκείνα του k-means:

- Το μεγάλο cluster περιέχει ~35% ακυρωμένες κρατήσεις και ~65% μη ακυρωμένες.

- Το μικρό cluster αποτελείται αποκλειστικά από `Not_Canceled` κρατήσεις.

Συνεπώς, για $k=2$ οι δύο μέθοδοι (k -means και ιεραρχική με Ward) δίνουν πρακτικά την ίδια ομαδοποίηση: ίδια μεγέθη clusters, ίδια μέση συμπεριφορά στις βασικές μεταβλητές και ίδια κατανομή ακυρώσεων. Αυτό καθιστά τη σύγκρισή τους ιδιαίτερα “καθαρή” και ενισχύει τη σταθερότητα των ευρημάτων.

6. Συζήτηση αποτελεσμάτων και απάντηση στα ερωτήματα της εργασίας

6.1 Περιγραφή των ομάδων (απάντηση στο Β – «Πώς θα περιγράφατε τις ομάδες;»)

Και οι δύο μέθοδοι (k -means και ιεραρχική Ward) με ($k = 2$) οδηγούν ουσιαστικά στα ίδια δύο clusters, με ίδια μεγέθη, παρόμοια κεντροειδή και ίδια κατανομή ως προς τις βασικές μεταβλητές:

- **Cluster 1 – “Τυπικές κρατήσεις πρώτης επίσκεψης” (≈ 1950 κρατήσεις)**
 - Περίπου 2 άτομα ανά κράτηση (τυπικές κρατήσεις ζευγαριών/μικρών παρέων).
 - Διαμονή γύρω στις 3 νύχτες.
 - Μεγαλύτερο lead time (κρατήσεις αρκετές εβδομάδες ή και μήνες πριν).
 - Μεσαίο επίπεδο μέσης τιμής δωματίου.
 - Σχεδόν καμία προηγούμενη κράτηση ή ακύρωση (`has_prev_booking  $\approx 0$` , `has_prev_cancel  $\approx 0$`).

Αυτό το cluster αντιστοιχεί σε “νέους” πελάτες, χωρίς ιστορικό με το ξενοδοχείο, που οργανώνουν τη διαμονή τους σχετικά έγκαιρα.

- **Cluster 2 – “Συχνοί πελάτες, last-minute, χαμηλότερης τιμής” (≈ 50 κρατήσεις)**
 - Μικρότερο μέσο μέγεθος παρέας ($\approx 1-1.5$ άτομα).
 - Πιο σύντομη διαμονή (≈ 2 νύχτες).
 - Πολύ μικρό lead time (κρατήσεις τελευταίας στιγμής, λίγες μέρες πριν).
 - Χαμηλότερη μέση τιμή ανά κράτηση.
 - Σχεδόν όλοι έχουν προηγούμενες κρατήσεις, και αρκετοί έχουν ιστορικό ακύρωσης (`has_prev_booking  $\approx 1$` , αυξημένο `has_prev_cancel`).

Το cluster αυτό περιγράφει μια μικρή αλλά πολύ “ειδική” ομάδα επαναλαμβανόμενων πελατών, που φαίνεται να εκμεταλλεύονται χαμηλότερες τιμές ή last-minute διαθεσιμότητα.

Τα παραπάνω συμπεράσματα στηρίζονται στα προφίλ των clusters που υπολογίστηκαν τόσο για τον k -means όσο και για την ιεραρχική ομαδοποίηση, καθώς και στις οπτικοποιήσεις (π.χ. `kmeans.png`).

6.2 Ποια clusters έχουν τις περισσότερες ακυρώσεις; (μέρος του Β)

Χρησιμοποιώντας τις κατανομές `booking.status` ανά cluster (γραφήματα `kmeanscancel.png` και `dendrocancel.png`) προκύπτει ότι:

- Στο **μεγάλο Cluster 1** περίπου **35%** των κρατήσεων είναι `Canceled` και **65%** είναι `Not_Canceled`.
- Στο **μικρό Cluster 2** οι κρατήσεις είναι **100% Not_Canceled** στο τρέχον dataset.

Άρα, όλες οι ακυρωμένες κρατήσεις συγκεντρώνονται στο μεγάλο, “τυπικό” cluster, ενώ το μικρό cluster των συχνών, last-minute πελατών εμφανίζει μηδενικό ποσοστό ακυρώσεων στις συγκεκριμένες παρατηρήσεις. Αυτό είναι ενδιαφέρον, γιατί δείχνει ότι, παρότι οι πελάτες του Cluster 2 έχουν ιστορικό προηγούμενων ακυρώσεων, οι τρέχουσες κρατήσεις τους στο δείγμα είναι σταθερές. Μια πιθανή ερμηνεία είναι ότι πρόκειται για “ώριμους” πελάτες που γνωρίζουν καλύτερα πότε θα ταξιδέψουν και κάνουν κράτηση πολύ κοντά στην ημερομηνία άφιξης, μειώνοντας την ανάγκη ακύρωσης.

6.3 Πόσο καλά είναι τα clusters και σύγκριση μεθόδων (απάντηση στο A & B)

Η ποιότητα των clusters (ως προς τη συνοχή και τον διαχωρισμό τους) αξιολογήθηκε κυρίως με τον μέσο δείκτη **silhouette**:

- Για το τελικό σύνολο μεταβλητών και ($k = 2$), τόσο ο **k-means** όσο και η **ιεραρχική Ward** δίνουν **mean silhouette ≈ 0.72** , τιμή που θεωρείται υψηλή και υποδηλώνει καθαρό διαχωρισμό ομάδων.
- Για μεγαλύτερα (k) (3–8) ο μέσος silhouette πέφτει σημαντικά (≈ 0.28 – 0.31), δείχνοντας ότι ο επιπλέον διαχωρισμός δεν βελτιώνει τη δομή των clusters.

Η σύγκριση των δύο μεθόδων δείχνει ότι:

- Παράγουν **ίδια μεγέθη clusters** (1952 και 48 κρατήσεις).
- Τα **προφίλ** ανά cluster (μέσοι όροι **persons**, **nights**, **lead.time**, **average.price**, ιστορικό κρατήσεων/ακυρώσεων) είναι πρακτικά ταυτόσημα.
- Η **κατανομή ακυρώσεων** ανά cluster είναι επίσης ίδια (όλες οι ακυρώσεις στο μεγάλο cluster, καμία στο μικρό).
- Οι τιμές του **silhouette** είναι ίδιες, κάτι που δηλώνει παρόμοια ποιότητα διαχωρισμού.

Συνεπώς, και οι δύο μέθοδοι επιβεβαιώνουν μια σταθερή, δι-ομαδική δομή στα δεδομένα: ένα μεγάλο, ετερογενές cluster “τυπικών” πελατών και ένα μικρό, πολύ συμπαγές cluster επαναλαμβανόμενων, last-minute πελατών. Αυτό ενισχύει την αξιοπιστία των αποτελεσμάτων και απαντά θετικά στο ερώτημα “πόσο καλά είναι τα clusters;”, καθώς η λύση με ($k = 2$) φαίνεται ταυτόχρονα ποιοτικά καλή και ερμηνεύσιμη επιχειρησιακά.